

LAPORAN TEKNIS CAPSTONE FinSight: End-to-End Machine Learning Pipeline untuk Behavioral Persona Clustering

Disusun Oleh Tim:

1. **Anargya Isadhi Maheswara** (CACC001D6Y2600) – *AI Engineer*
2. **Faqih Firman Pratama** (CACC001D6Y2079) – *AI Engineer*
3. **Alden Nabil Wibowo Effendy** (CDCC001D6Y0747) – *Data Scientist*
4. **Qaulan Sadiida Putri Sumarna** (CDCC001D6X1394) – *Data Scientist*
5. **Daffa Aulia Musyaffa Subyantoro** (CFCC001D6Y1542) – *Full Stack*
6. **Hilfani Rayyanne Subagio** (CFCC001D6X1108) – *Full Stack*

**DBS Coding Camp 2026
2026**

Executive Summary

Proyek FinSight merupakan solusi analitik berbasis kecerdasan buatan (AI) yang dirancang untuk mengatasi masalah *blank spot* pada data mutasi transaksi perbankan dan memetakan nasabah ke dalam persona psikologi finansial (*Behavioral Finance*). Dengan memadukan *Natural Language Processing* (Multinomial Naive Bayes) untuk klasifikasi transaksi dan algoritma K-Medoids (PAM) untuk *clustering*, sistem ini secara otomatis mengelompokkan nasabah menjadi tiga persona utama: *Spendthrift*, *Unconflicted*, dan *Tightwad*. Evaluasi ekstrinsik membuktikan bahwa algoritma K-Medoids memiliki ketangguhan (*robustness*) yang superior terhadap anomali pengeluaran dibandingkan K-Means, dibuktikan dengan skor *Adjusted Rand Index* (ARI) dan *Normalized Mutual Information* (NMI) yang optimal.

BAB 1: Problem Discovery & Business Case

1.1 Latar Belakang Masalah

Industri perbankan saat ini memiliki miliaran baris data transaksi nasabah. Namun, bank sering kali kesulitan memberikan saran keuangan (*financial advisory*) yang bersifat *hyper-personalized*. Hambatan utama terletak pada tingginya area *blank spot* pada data mutasi (seperti transaksi berlabel "Transfer P2P" atau "QRIS") serta belum adanya kerangka pemetaan psikologi finansial

otomatis yang mengacu pada standar rasio perencanaan keuangan 50/30/20 (Needs, Wants, Investasi).

1.2 Business Objective

Proyek ini bertujuan untuk membangun sebuah *end-to-end Machine Learning Pipeline* (FinSight) yang bertugas membersihkan, mengkategorikan data mentah mutasi rekening, dan mengagregasinya menjadi profil bulanan untuk dikelompokkan ke dalam tiga persona *Behavioral Finance*.

1.3 Scope & Batasan Proyek

Mengingat regulasi privasi data perbankan yang ketat, pengembangan model dibatasi menggunakan pabrik data sintetis yang merepresentasikan 500 nasabah simulasi selama 90 hari. Pemodelan mencakup arsitektur NLP dan Benchmarking Clustering.

BAB 2: Metodologi & Data Generation

2.1 Arsitektur Mesin Pembangkit Data

Pembangkitan data dilakukan secara dinamis menggunakan distribusi Poisson (λ) yang diatur berdasarkan persona dasar nasabah. Sistem menginjeksi pencilan perilaku (*Behavioral Outliers*) melalui *multiplier* harga acak (3x - 8x lipat) dengan probabilitas 2% pada setiap transaksi untuk menguji ketangguhan model. Logika "Survival Mode" dinonaktifkan secara spesifik bagi persona *Spendthrift* untuk menjaga varians data dan menghindari fenomena *Label Noise* pada tahapan akhir.

BAB 3: Pemrosesan Bahasa Alami (NLP Pipeline)

3.1 Evaluasi Intrinsik & Ekstrinsik

Dari 150.274 total transaksi, terdapat 8.543 transaksi Transfer P2P (5,69%) yang menjadi subjek klasifikasi NLP. Tantangan utama terletak pada heterogenitas teks: sistem harus mampu membedakan "bayar gacoan" (F&B) dari "beli baju" (Fashion) dari "patungan spotify" (Hiburan), semuanya dalam format teks informal, singkatan, dan diksi gaul khas mahasiswa.

Distribusi Ground Truth pada transaksi Transfer P2P:

Kategori Sebenarnya	Jumlah
Transfer P2P (tetap ambigu)	6.301
Tagihan & Utilitas	624
Hiburan & Langganan	509
Belanja Online & Fashion	476
F&B dan Nongkrong	399

4.2 Arsitektur NLP

Pipeline NLP dirancang dalam tiga tahap berurutan:

1. Feature Fusion & Text Cleaning

Kolom deskripsi mutasi dan catatan mutasi digabungkan menjadi satu fitur teks tunggal (teks kotor). Pembersihan dilakukan menggunakan Regex: case folding ke huruf kecil, penghapusan seluruh karakter non-alfanumerik, dan normalisasi spasi ganda. Tahap ini tidak menggunakan stopwords removal atau stemming agar kata-kata pendek informal seperti "kos", "mabar", atau "gacoan" tidak ikut terhapus.

2. TF-IDF Feature Extraction

Teks bersih ditransformasi menggunakan TF-IDF Vectorizer dengan N-Gram (1, 2). Penggunaan bigram memungkinkan model menangkap frasa bermakna seperti "beli aju" atau "bayar gacoan" sebagai unit fitur tunggal, bukan sekadar kata berdiri sendiri. Matriks TF-IDF yang dihasilkan berukuran (8.543×6.190) —artinya 6.190 kombinasi kata unik menjadi ruang fitur model.

3. Multinomial Naive Bayes Training

Dataset dibagi dengan rasio 80:20 menggunakan stratified split untuk menjaga proporsi kelas yang seimbang. Model Multinomial Naive Bayes dilatih pada 6.834 data dan diuji pada 1.709 data.

3.1 Evaluasi Intrinsik & Ekstrinsik

Model berhasil mencapai akurasi keseluruhan 99% pada data uji. Perincian performa per kelas:

Kategori	Precision	Recall	F1-Score
Belanja Online & Fashion	0.99	0.96	0.97
F&B dan Nongkrong	1.00	0.95	0.97
Groceries & Kebutuhan Pokok	1.00	0.96	0.98
Hiburan & Langganan	0.99	0.98	0.99
Tagihan & Utilitas	0.93	1.00	0.96
Transfer P2P	1.00	1.00	1.00

Kelas "Transfer P2P" mencapai F1-Score sempurna karena volume besar sampel yang homogen. Kelas "Tagihan & Utilitas" memiliki Precision terendah (0.93) karena sebagian kecil teks tagihan seperti "beli token" dapat tumpang tindih secara leksikal dengan konteks pembelian biasa. Model kemudian diekspor sebagai file untuk digunakan langsung dalam dashboard produksi.

BAB 4: Feature Engineering

4.1 Filosofi Desain Fitur

Agregasi dilakukan pada tingkat per nasabah per bulan, menghasilkan 1.500 observasi ($500 \text{ nasabah} \times 3 \text{ bulan}$). Pendekatan bulanan ini kritis untuk dua alasan: (1) menangkap Persona Shift—perubahan perilaku nasabah antar bulan yang tidak akan terdeteksi jika data dirata-rata, dan (2) melipatgandakan jumlah sampel latih yang tersedia bagi algoritma clustering.

Seluruh nilai nominal dikonversi menjadi rasio persentase terhadap gaji bulanan untuk menghilangkan bias ketimpangan pendapatan antar nasabah. Nasabah bergaji Rp 10 juta yang menghabiskan Rp 5 juta untuk hiburan dan nasabah bergaji Rp 3 juta yang menghabiskan Rp 500 ribu untuk hal serupa keduanya harus dapat dibandingkan secara setara.

4.2 Evaluasi Intrinsik & Ekstrinsik

Setelah pelabelan bersih, puluhan kategori detail dipetakan kembali menjadi 3 pilar utama (Needs, Wants, Investasi). Data dilakukan *pooling* per bulan sehingga menghasilkan 1.500 observasi (500 nasabah x 3 bulan). Konversi nilai nominal menjadi rasio persentase dilakukan guna menghilangkan bias gaji atau ketimpangan pendapatan antar nasabah. Data rasio ini kemudian dimasukkan ke arena *benchmarking* yang menguji kapabilitas K-Means, K-Medoids, dan Agglomerative Clustering.

Kelompok	Fitur	Logika Konstruksi
Core Ratios	<i>wants ratio</i>	Total Nominal Wants / Total Pengeluaran
Core Ratios	<i>savings rate</i>	(Investasi + Saldo Bulanan) / Gaji
Core Ratios	<i>fixed costs ratio</i>	Total Nominal Needs / Total Pengeluaran
Habits & Pain	<i>wants frequency</i>	Jumlah Transaksi Wants / Total Transaksi
Habits & Pain	<i>small leaks ratio</i>	Transaksi < Rp 30.000 / Total Transaksi
Temporal	<i>night owl spending</i>	Transaksi 22:00–04:00 / Total Transaksi
Temporal	<i>weekend surge</i>	Mean Nominal Weekend / Mean Nominal Weekday
Temporal	<i>early month depletion</i>	Pengeluaran 5 Hari Pertama Pasca-Gajian / Gaji
Survival	<i>balance volatility</i>	Standar Deviasi Saldo Harian / Gaji
Survival	<i>survival mode days</i>	Jumlah Hari Saldo < 15% Gaji

BAB 5: Reduksi Dimensi

5.1 Analisis Korelasi

Sebelum memasuki tahap clustering, dilakukan analisis korelasi antar fitur. Ditemukan empat pasang fitur dengan korelasi tinggi

Pasangan Fitur	Korelasi
<i>wants_ratio</i> dan <i>wants_frequency</i>	+0.870
<i>fixed_costs_ratio</i> dan <i>wants_frequency</i>	-0.752
<i>savings_rate</i> dan <i>balance_volatility</i>	-0.764

Korelasi ini bersifat logis secara perilaku (nasabah yang sering jajan memang cenderung jarang menabung), namun berbahaya bagi algoritma berbasis jarak karena akan menyebabkan double-counting pengaruh fitur yang berkorelasi. Masalah ini diatasi melalui reduksi dimensi.

5.2 Validasi Kecenderungan Clustering

Sebelum memaksakan model, dilakukan uji apakah data secara alami membentuk struktur cluster. Hopkins Statistic (H) yang mendekati 1.0 mengindikasikan kecenderungan clustering yang kuat:

Dataset	Hopkins Statistic	Interpretasi
Core_NoPCA	0.8024	Terdapat Struktur Cluster
Core_PCA	0.8368	Terdapat Struktur Cluster
Core_UMAP	0.9586	Struktur Sangat Kuat
All_NoPCA	0.7370	Terdapat Struktur Cluster
All_PCA	0.7429	Terdapat Struktur Cluster
All_UMAP	0.9753	Struktur Sangat Kuat

Hasil yang menonjol adalah nilai Hopkins untuk ruang UMAP yang mendekati sempurna (0.975 dan 0.959). Ini mengonfirmasi bahwa UMAP mampu memproyeksikan fitur perilaku ke dalam geometri 2D yang jauh lebih terstruktur secara klasteral dibandingkan PCA.

5.3 Empat Varian Dataset Komparasi

Untuk mengisolasi kontribusi pemilihan fitur vs. metode reduksi dimensi, dibangun empat dataset komparasi:

Kode Dataset	Fitur	Reduksi	Dimensi Output
Core_NoPCA	3 Fitur Inti	Tidak ada	3D
Core_PCA	3 Fitur Inti	PCA (2 PC)	2D
Core_UMAP	3 Fitur Inti	UMAP	2D
All_NoPCA	10 Fitur Lengkap	Tidak ada	10D
All_PCA	10 Fitur Lengkap	PCA (7 PC, 95% variansi)	7D
All_UMAP	10 Fitur Lengkap	UMAP	2D

PCA pada 10 Fitur Lengkap mempertahankan 95% variansi dengan hanya 7 komponen utama, mengkonfirmasi bahwa korelasi tinggi antar fitur menyebabkan redundansi informasi yang signifikan.

BAB 6: Benchmarking Algoritma Clustering

6.1 Algoritma yang Diuji

Empat algoritma diadu pada semua dataset: K-Means, K-Medoids (PAM dengan jarak Manhattan), Agglomerative Clustering (Manhattan, average linkage), dan Gaussian Mixture Model (GMM). Jumlah cluster ditetapkan K=3 sesuai dengan tiga persona target (Tightwad, Unconflicted, Spendthrift).

K-Medoids diimplementasikan secara manual menggunakan jarak Manhattan (bukan Euclidean) karena metrik ini lebih robust terhadap distribusi data yang

tidak normal dan cocok untuk ruang fitur perilaku yang memiliki ekor distribusi panjang.

6.2 Metrik Evaluasi

Metrik	Jenis	Interpretasi
Silhouette Score	Intrinsik	Semakin mendekati 1 = cluster lebih padat & terpisah
Davies-Bouldin Index (DBI)	Intrinsik	Semakin kecil = semakin baik
Calinski-Harabasz Index (CHI)	Intrinsik	Semakin besar = cluster lebih kompak & terpisah
Adjusted Rand Index (ARI)	Ekstrinsik	Kemiripan dengan Ground Truth; 1=sempurna, 0=acak

6.3 Hasil Benchmarking

Dari 24 kombinasi (6 dataset × 4 algoritma) yang diuji, berikut adalah lima terbaik berdasarkan Silhouette Score. Untuk All_UMAP, seluruh algoritma menghasilkan skor identik sehingga cukup diwakili oleh satu baris.

Peringkat	Dataset	Algoritma	Silhouette	DBI	CHI	ARI
1	All_UMAP	Gaussian Mixture	0.6195	0.4642	4783.99	0.3593
2	Core_UMAP	K-Medoids	0.5456	0.6265	2184.87	0.3986
3	Core_UMAP	K-Means	0.5443	0.6180	2189.29	0.3973
4	Core_NoPCA	K-Means	0.512	0.569	1073	0.358
5	Core_PCA	K-Means	0.4997	0.6895	1794.81	0.3864

6.3 Analisis Komparatif

A. Pola Konvergensi Identik pada All_UMAP

Keempat algoritma pada All_UMAP menghasilkan skor yang persis sama di semua metrik. Ini bukan kebetulan statistik, melainkan fenomena geometri yang dapat dijelaskan:

UMAP, ketika diterapkan pada 10 fitur perilaku finansial yang kaya, berhasil memproyeksikan data ke dalam dua "pulau" kluster yang terpisah dengan jarak yang sangat besar dan hampir tidak tumpang tindih. Ketika cluster sudah sangat terpisah secara spasial seperti ini, semua algoritma akan menghasilkan assignment keanggotaan yang identik.

B. Perbandingan Lintas Kelompok: UMAP vs. PCA vs. Tanpa Reduksial dan cocok untuk ruang fitur perilaku yang memiliki ekor distribusi panjang.

Aspek	All_UMAP	Core_NoPCA	Core_PCA	All_PCA	All_NoPCA
Silhouette Score	0.619	0.51	0.50	0.41	0.24
Hopkins Statistic	0.975	0.802	0.837	0.743	0.737
Peningkatan vs. Tanpa Reduksi	+157%	-	-	+70%	Baseline
Algoritma Terbaik	Semua setara	K-Means	K-Means	K-Means	K-Means

6.4 Profiling Klaster

Centroid klaster diidentifikasi berdasarkan agregasi rata-rata fitur inti:

Klaster	Wants Ratio	Savings Rate	Karakteristik
---------	-------------	--------------	---------------

Cluster dengan wants_ratio > 50% dan savings_rate < 0	Tinggi	Negatif	Spendthrift
Cluster dengan wants_ratio < 35%	Rendah	Tinggi	Tightwad
Cluster moderat	Sedang	Positif	Unconflicted

BAB 7: Kesimpulan & Rekomendasi

Implementasi FinSight terbukti mampu memetakan perilaku finansial nasabah dengan efisiensi tinggi tanpa membebani komputasi server. Sebagai rekomendasi bisnis ke depan, label *Spendthrift* dan *Tightwad* yang dihasilkan dapat diintegrasikan langsung dengan *Customer Relationship Management* (CRM) bank untuk *targeted marketing*, seperti menawarkan promo F&B kepada *Spendthrift* atau produk Reksa Dana kepada *Tightwad*.